

Fonction de perte quadratique et dérivées de matrices

m : exemples, d : dimension

On représente les données par une matrice à m lignes et d colonnes (les exemples toujours en ligne) : $X \in \mathbb{R}^{m \times d}$

Fonction de perte : $J(\theta) = \frac{1}{2m} \sum_{j=1}^m (\theta^T x^j - y^j)^2$

On peut écrire cette somme sous forme d'un produit de matrices :

$$J(\theta) = \frac{1}{2m} \underbrace{(X\theta - \vec{y})^T}_{m \times d \times d \times 1} \underbrace{(X\theta - \vec{y})}_{d \times 1 \times m \times 1}$$

$X\theta$ est de dimension $m \times 1$
et $(X\theta - \vec{y})^T (X\theta - \vec{y})$ est bien un scalaire.

Développons J en laissant tomber la constante $\frac{1}{2m}$:

$$\begin{aligned} J(\theta) &= (X\theta - \vec{y})^T (X\theta - \vec{y}) = ((X\theta)^T - \vec{y}^T) (X\theta - \vec{y}) \\ &= (X\theta)^T X\theta - (X\theta)^T \vec{y} - \vec{y}^T (X\theta) + \vec{y}^T \vec{y} \end{aligned}$$

on a $(X\theta)^T \vec{y} = \vec{y}^T (X\theta)$ car c'est un scalaire.

$$\text{d'où } J(\theta) = \theta^T X^T X \theta - 2(X\theta)^T \vec{y} + \vec{y}^T \vec{y}$$

On dérive par rapport à θ :

$$\frac{dJ(\theta)}{d\theta} = 2X^T X \theta - 2X^T \vec{y} + 0 = 0$$

$$\Rightarrow X^T X \theta = X^T \vec{y}$$
$$\Rightarrow \boxed{\theta = (X^T X)^{-1} X^T \vec{y}}$$

A vous de vous convaincre que $\frac{d}{d\theta} (\theta^T X^T X \theta) = 2X^T X \theta$
et $\frac{d}{d\theta} (X\theta)^T = \frac{d}{d\theta} (\theta^T X^T) = X^T$...